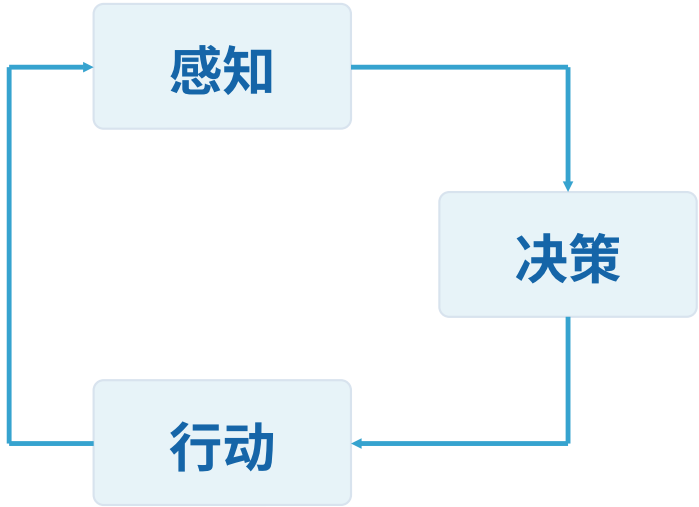
智能体综述 / 全景

从广义 Agent 到大模型智能体

概念与历史建立边界
案例与架构解释机制



大数据科学与产业研究院
演化科学智能山西省重点实验室

汇报人：左金隆 | 2026 年 10 月 27 日

五章构成全景：本轮先建立概念与架构

整场约 150 分钟；本轮完成前两章，后续围绕论文、应用与评估展开。

01	智能体的概念与发展历程	定义 · 特征 · 环境交互 · 并行发展
02	大模型智能体的核心架构	上海案例 · 执行闭环 · 规划 / 记忆 / 工具
03	代表性研究工作与关键技术	重点： ReAct （ICLR 2023）与 Reflexion （NeurIPS 2023）
04	智能体的典型应用与实践	后续补充应用场景与可复现实践
05	智能体的评估、挑战与发展趋势	后续讨论可靠性、成本与开放问题

智能体的本质：在环境中感知并采取行动

以下为中文释义：三种经典视角强调不同侧面，并不限定决策必须由 LLM 实现。

RUSSELL & NORVIG · 1995

感知—行动视角

通过传感器感知环境，
通过执行器对环境行动。

关注：系统与环境的接口。

FRANKLIN & GRAESSER · 1997

持续、嵌入的主体

处于环境之中，持续感知、行动，并追求自身议程。

关注：行动影响后续感知。

WOOLDRIDGE & JENNINGS · 1995

弱智能体概念

用自主性、社会性、反应性和主动性描述一类系统。

关注：行为与控制特征。

目标可以由设计者或用户给定；行为是否合理，需要结合任务的性能标准评价。

共同关注的是“系统如何行动”，而不是“系统是否拥有大语言模型”。

[1] Russell & Norvig, AIMA, 1995, Ch.2 [2] Franklin & Graesser, ATAL 1996 / 1997 [3] Wooldridge & Jennings, KER, 1995

四个典型特征描述行为，不是一张统一的准入清单

以扫地机器人为例：自主性是授权范围内的控制能力，不等于不受约束。

01 • AUTONOMY

自主性 独立管理自身状态与行动。

例：按任务自行完成房间清扫。

02 • REACTIVITY

反应性 感知环境变化，并及时作出响应。

例：遇到障碍时改变行进方向。

03 • PROACTIVITY

主动性 围绕目标采取主动行为。

例：电量不足时主动规划回充。

04 • SOCIAL ABILITY

社会性 与人或其他 Agent 通信、协作。

例：向用户报告卡困并请求协助。

这些能力早于 LLM；不同系统具备的程度、组合及实现方式并不相同。

[3] Wooldridge & Jennings, 1995, “weak notion of agency”

广义 Agent 的核心机制是“感知—决策—行动”闭环

扫地机器人只需传感器、控制策略与执行器，也可以构成智能体。



观察通常只是环境状态的一部分；反馈不一定是奖励，运行时也不一定进行学习。

Agent 本身也可以是传统程序；关键在于其在环境中的角色与交互方式。

[1] AIMA, Ch.2 [4] Sutton & Barto, Reinforcement Learning: An Introduction, 2nd ed., 2018, Ch.3

发展历程：目标未变，决策、学习与行动的技术在演变

代表节点按年代排列（非等距）；三类路线长期并行，也会在同一系统中组合。

符号、规则与搜索

1971 / 1995 / 1997



STRIPS · BDI · Deep Blue

显式知识表示与计划

规则、启发式搜索

→

强化学习与搜索

长期发展 · 2016 代表



AlphaGo

策略 / 价值学习

结合监督学习与树搜索

→

大语言模型驱动

2022—2023 起快速发展

ReAct / AutoGPT

语言模型参与决策

连接工具与外部反馈

1971 STRIPS

1995 BDI 代表论文

1997 Deep Blue

2016 AlphaGo

2023 AutoGPT

智能体的基本目标没有改变，变化的是驱动其决策、学习和行动的技术手段。

[5] STRIPS, 1971 [6] BDI, 1995 [7] Deep Blue, 2002 [8] AlphaGo, 2016 [9] AutoGPT 官方项目 , 2023 起

从 LLM 到 LLM Agent： 把生成能力嵌入任务执行系统

这里比较三种典型配置；产品能力存在连续谱，工具聊天系统也可能具备 Agent 特征。

配置 A

基础 LLM

从输入上下文生成输出

未连接工具时：
不能自行查询实时数据，
也不能直接操作外部软件。

配置 B

工具增强聊天系统

可在对话中搜索或计算

常由用户逐轮推进；
任务状态、验证和终止机制
取决于系统实现。

配置 C

自主任务执行型 Agent

围绕目标连续选择行动

维护执行状态，
依据环境反馈修正计划，
直到完成或触发停止条件。

长程任务的难点不仅是“会回答”，还包括执行、验证、状态管理和错误恢复。

LLM 提供语言理解与决策能力；系统负责把决策落实为可检查的执行过程。

[10] Wang et al., 2023, arXiv:2308.11432 [11] Xi et al., 2023, arXiv:2309.07864

上海一日游：生成一个 480 元方案，只是任务的起点

教学示例：所有价格均沿用原稿的假设数据，不代表实时查询结果或实际报价。

用户任务

“帮我规划上海一日游”

预算 ⩽ 500 元
核对行程与费用

初步规划 | 待验证

外滩＋南京路	0
午餐：本帮菜	120
豫园	80
城隍庙＋游船	220
交通：地铁	60

初步合计： 480 元

工具查询 → 外部观察

查询交通、景点与餐饮
发现本帮菜费用为 220 元

480 → 580 元

超出预算 80 元，需要修正。

计划是待验证的假设；环境反馈可以否定模型最初的判断。

案例与费用：原稿第 6—9 页；本稿重绘。查询交通、景点、餐饮的过程均为机制示意。

依据反馈重规划：改变行动选择，而不是修改事实

发现约束冲突 → 查找替代方案 → 重新计算与检查 → 输出最终行程。

项目	初始预估	反馈后方案	重规划方案
上午 | 外滩＋南京路	0	0	0
午餐 | 本帮菜 → 东北菜	**120**	**220**	**100**
下午 | 豫园	80	80	80
晚上 | 城隍庙＋游船	220	220	220
交通 | 地铁	60	60	60
合计 / 预算检查	**480 元 • 待核对**	**580 元 • 超预算**	**460 元 • 满足预算**

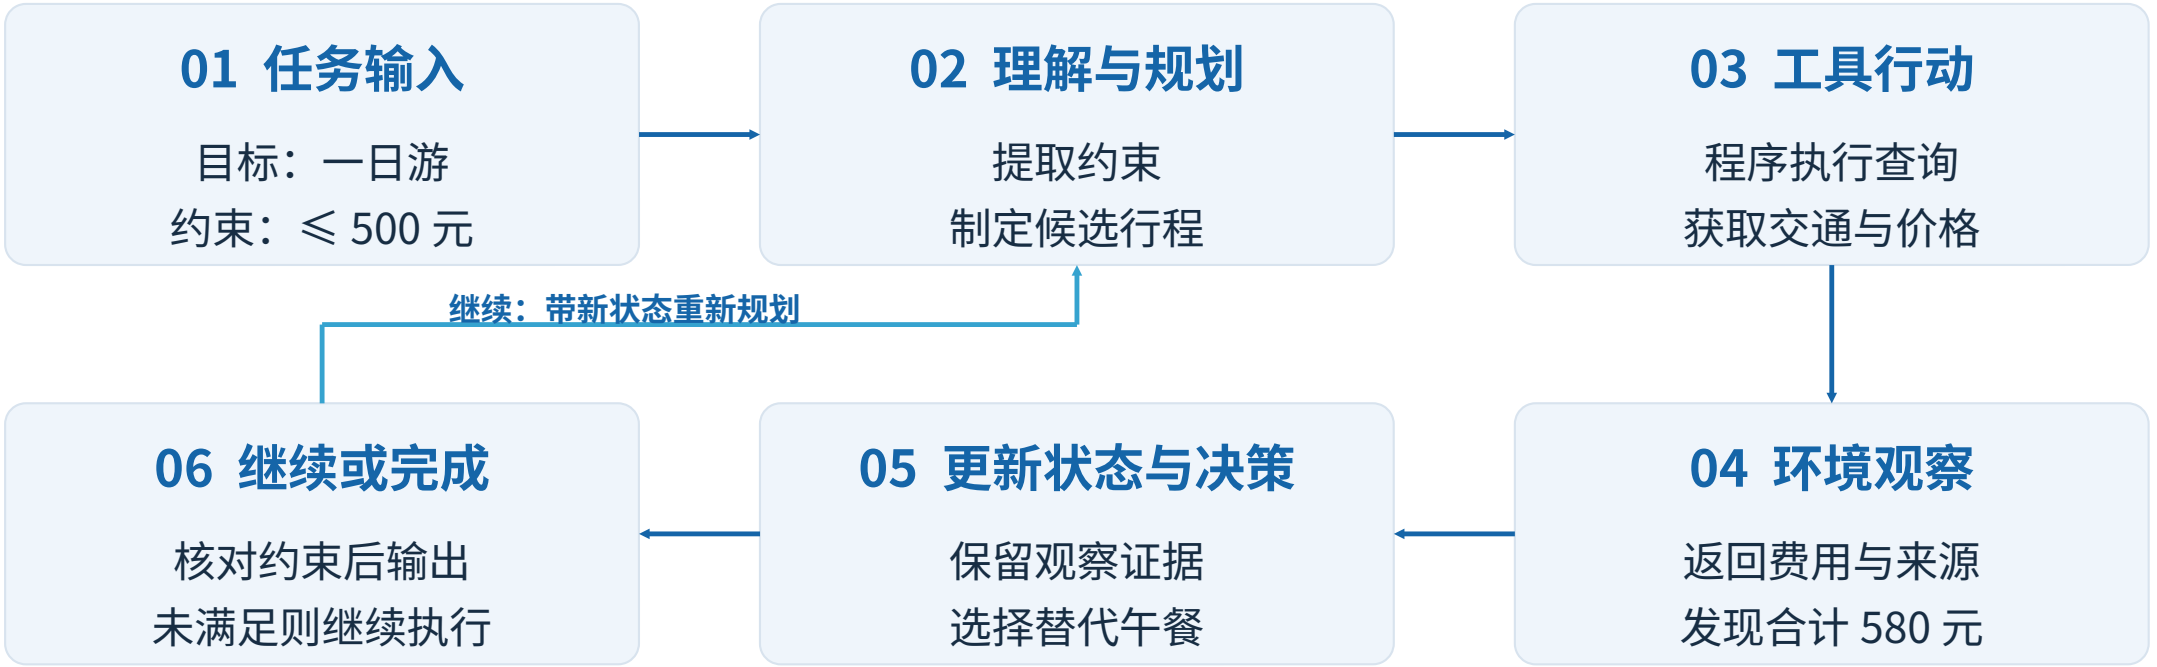
更换午餐后合计 460 元，预算余量 40 元；保留费用来源，并标注未验证条件。

Agent 不仅生成方案，还会利用环境反馈调整原有决策。

教学假设，非实时价格；本页只演示费用约束，真实行程还需验证时段、预约、路线与可用性。

任务执行闭环：让每次行动的结果进入下一轮决策

与第一章相比，这里明确 LLM 、工具执行、任务状态与停止条件的分工。

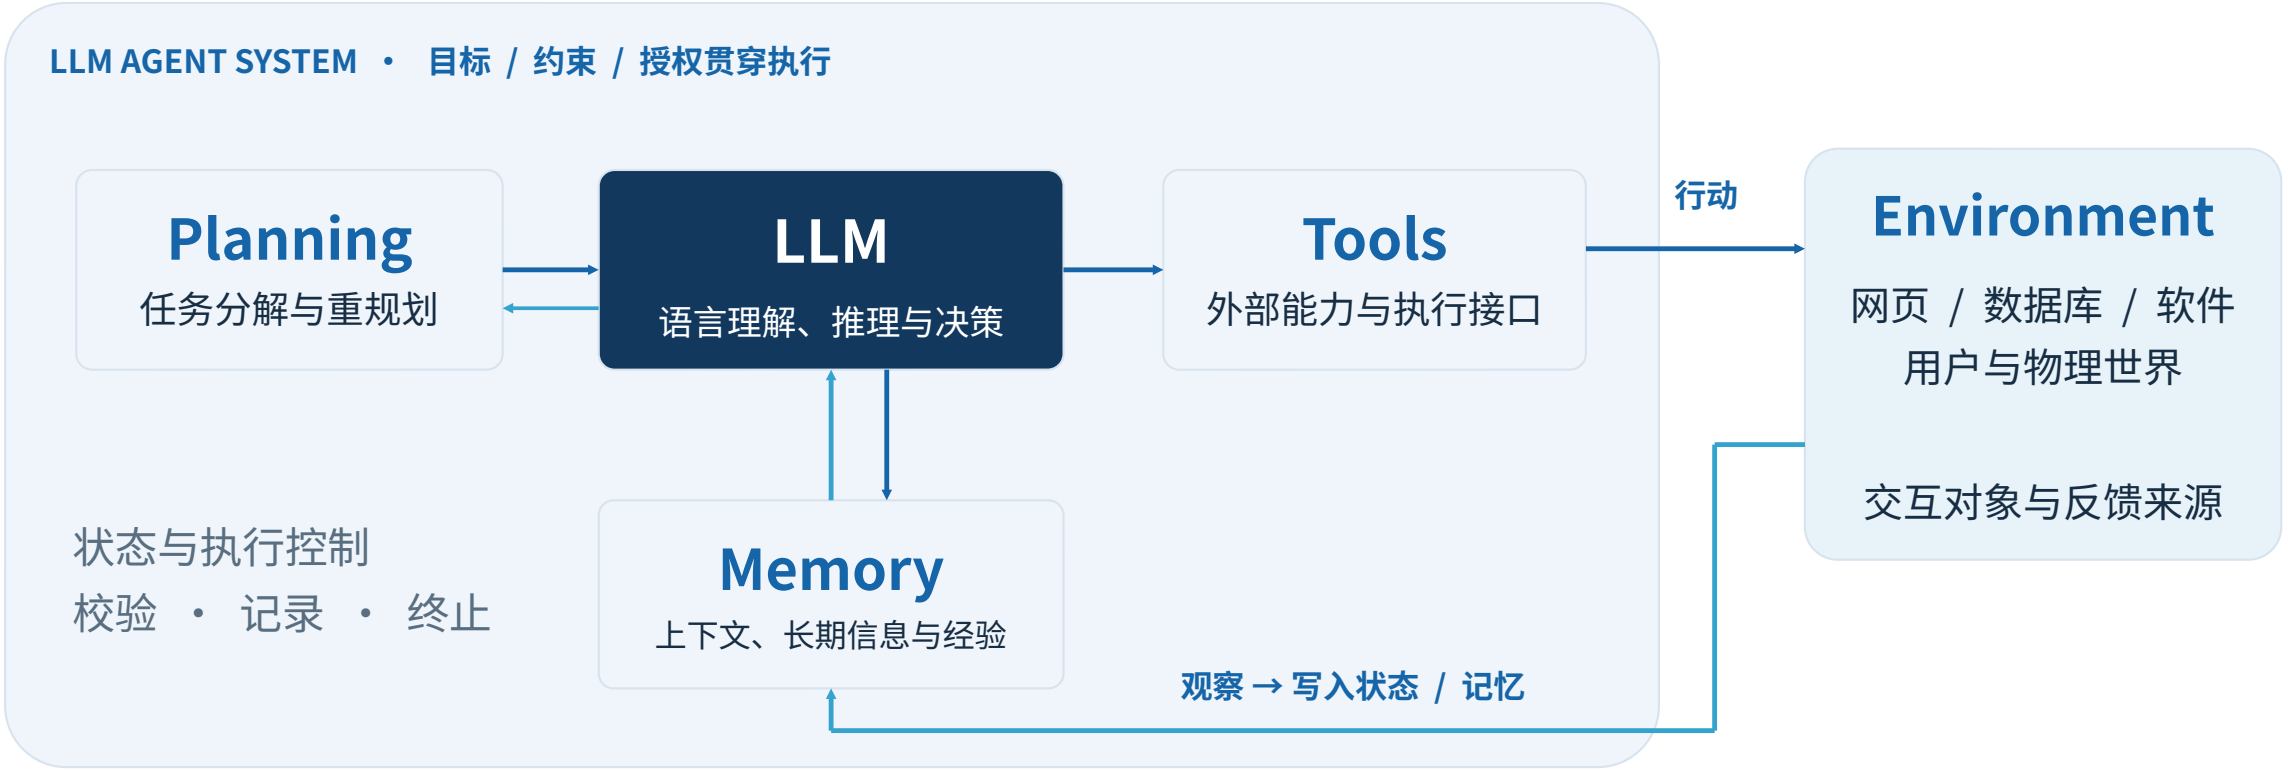


完成依赖结果核验；达到步数、时间或费用上限时，应停止并报告未完成项。

[10][11] LLM Agent 综述；流程为本稿教学抽象，并非所有系统都采用同一控制器。

整体架构： LLM 参与决策，模块共同支撑执行

这是一种综合教学抽象；规划、记忆与工具不一定是独立模型，也不要求全部显式部署。



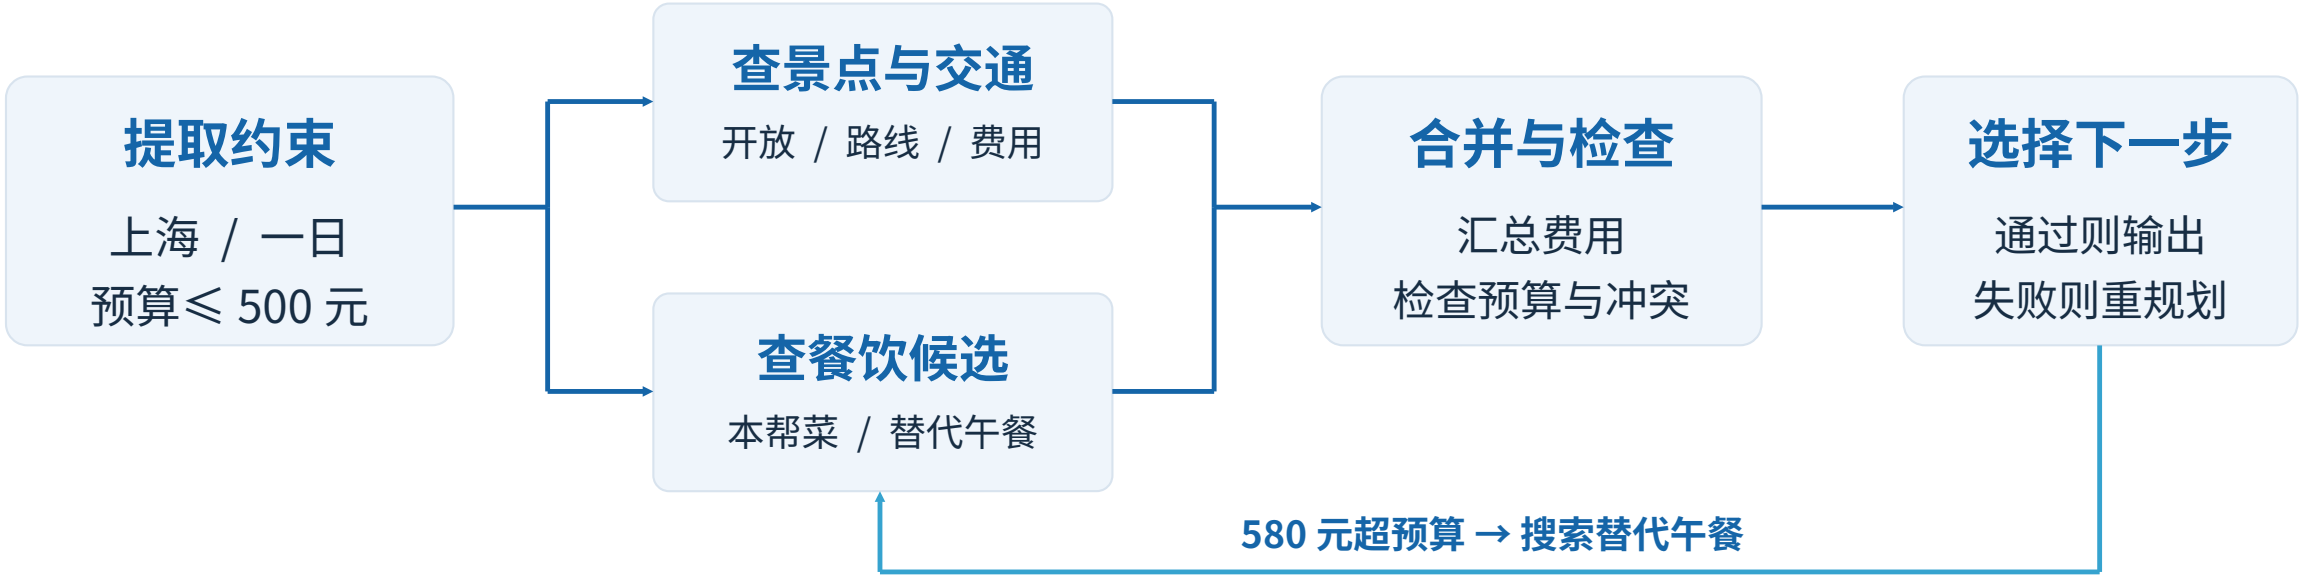
图中 Environment 位于系统边界之外；用户目标与工具返回经上下文进入下一轮 LLM 调用。

[10] Wang et al., 2023： profile / memory / planning / action [11] Xi et al., 2023： brain / perception / action

Planning：把目标变成可执行、可修正的子任务

为什么需要：长程任务包含依赖关系与约束，一次性文本生成难以保证执行可行。

上海案例 • 规划依赖



局限：分解可能遗漏约束；语言计划不保证可执行，需借助外部验证与重规划。

[5] Fikes & Nilsson, STRIPS, 1971 [10][11] LLM Agent 综述 [12] Yao et al., ReAct, ICLR 2023

Memory：让下一步决策记得目标、证据与经验

为什么需要：多步任务会积累观察与中间结果，仅靠当前一轮输入容易丢失状态。

短期上下文与工作状态

当前任务正在发生什么?

预算： 500 元
本帮菜： 220 元
当前候选合计： 580 元

长期信息

跨任务需要保留什么?

用户偏好、文档与历史记录；
按相关性检索，并核对来源。

经验管理

过去的经验如何复用?

记录失败原因与适用条件：
先核对费用，再承诺行程。

观察与结果 → 筛选 / 摘要 / 写入 → 检索 → 当前上下文

局限：摘要会丢信息，检索可能取错；写入经验不等于更新模型参数或保证进步。

[10][11] LLM Agent 综述 [13] Shinn et al., Reflexion: Language Agents with Verbal Reinforcement Learning, NeurIPS 2023

Tools：模型生成调用意图，执行器完成真实操作

为什么需要：外部信息访问、精确计算与软件操作需要真实的程序接口。

01 选择工具

LLM 选择工具
并生成参数

→

02 校验与调度

程序检查 Schema 、
权限与调用预算

→

03 执行工具

调用 API / 代码
返回结果或错误

→

04 写回观察

记录结果与来源
支持下一轮决策

示例：工具调用请求（不是已经执行）

```
query_price({"city":" 上海 ",
        "item":" 本帮菜午餐 "})
```

示例：执行器返回的观察

{ 费用 : 220, 币种 : CNY,
来源 : 教学数据 , 状态 : 成功 }

局限：格式正确不代表事实正确；仍需处理超时、伪造结果、权限与不可逆操作。

教程 3.2 Function Calling （官方源文件） [10][11] LLM Agent 综述；图中查询名与 JSON 为教学伪接口。

从单智能体到多智能体：分工扩展能力，也增加协作成本

多个工具不等于多个 Agent；多 Agent 意味着多个决策主体通过消息或共享状态协调。

单智能体

统一决策主体

规划 / 查询 / 检查

状态集中，调试较直接；
也可以并行调用多个工具。

多智能体 | 一种中心协调结构



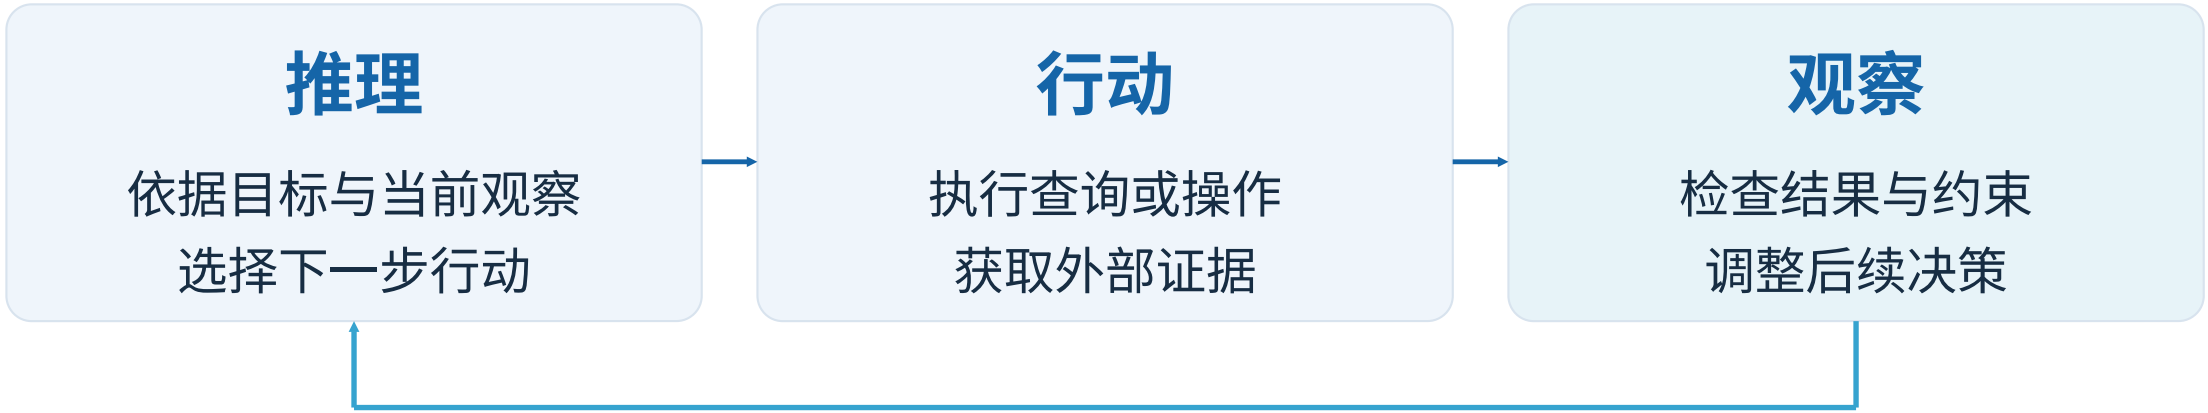
共享信息：子任务、证据、状态与结论。

收益来自合理分工；通信开销、状态冲突与相关性错误可能抵消收益。

[11] Xi et al., 2023： single-agent / multi-agent / human–agent cooperation；教程多智能体章节仅作组织参考。

从架构到方法：推理与行动如何在同一轨迹中交替？

我们已知道需要规划、记忆、工具与环境反馈；下一步研究它们如何被具体组织。



ReAct：一种交替组织推理轨迹、行动与观察的代表性研究思路

第三章继续： ReAct 如何组织单次执行？ Reflexion 如何利用语言反馈支持后续尝试？

[12] Yao et al., ReAct, ICLR 2023 （预印本 2022 ） [13] Shinn et al., Reflexion, NeurIPS 2023